Ajustements statistiques

Objectif

- Ajuster un nuage de points avec la fonction adaptée et prévoir des valeurs inconnues.

Activité 1 – Rappel sur l'ajustement affine

Un centre de supervision en cybersécurité surveille le réseau informatique de plusieurs entreprises. Depuis 5 ans, il enregistre le nombre d'attaques informatiques détectées chaque année.

Année	1	2	3	4	5
Nombre d'attaques détectées	95	120	176	231	264

Problématique : En quelle année le centre de supervision pourrait-il détecter 365 attaques, autrement dit une par jour ?

1. À l'aide de la fiche méthode, réaliser l'ajustement affine du nuage de points (année ; nombre d'attaques détectées).
2. L'ajustement affine est-il pertinent ? *Justifier avec la valeur de* R^2.

3. Utiliser l'équation de la droite d'ajustement pour répondre à la problématique.

Activité 2

En France, la stratégie nationale bas-carbone fixe un objectif de neutralité carbone en 2050, ce qui suppose de ramener les émissions annuelles à environ 80 MtCO2e, soit une baisse d'environ 85% par rapport à 1990.

Cette stratégie fixe aussi un objectif intermédiaire pour 2030 : une réduction des émissions de 50 % par rapport à 1990.

Pour plus d'informations : https://www.ecologie.gouv.fr/politiques-publiques/strategie-nationale-bas-carbone-snbc

Année	1990	1995	2000	2005	2010	2015	2020	2025
Rang de l'année	0	5	10	15	20	25	30	35
Emissions ($MtCO_2e$)	565	560	550	530	500	460	410	350

Problématique : Si la tendance se poursuit, la France pourrait-elle atteindre l'objectif de 2030 ?

1. Représenter le nuage de points (rang de l'année ; émissions).
2. Choisir le modèle le plus adapté entre affine, polynomial et exponentiel.

3. Valider votre choix en comparant le R^2 de chaque modèle.

4. Répondre à la problématique.

5. Discuter la validité du modèle pour 2050.

Activité 3

Bob est un célèbre archéologue. Il vient de découvrir une momie dans la vallée des Rois, en Égypte et souhaite déterminer son âge. Pour cela, il utilise la méthode de datation au carbone 14 (^{14}C). Accumulée par les organismes vivants, la quantité de carbone 14 diminue au cours du temps après leur mort.

Pour appliquer la méthode au carbone 14, Bob se base sur le tableau suivant.

Âge (en milliers d'années)	0	5	15	25	30
Taux de ^{14}C restant (en %)	100	56	20	7	4

Problématique : Quel est l'âge de la momie sachant qu'elle ne contient plus que 62 % de ^{14}C ?

1. Quel est l'âge d'un fossile qui ne contient plus que 4 % de carbone 14 ?

2. Représenter le nuage de points (âge ; taux de ^{14}C restant).
3. Choisir le modèle le plus adapté entre affine, polynomial de degré 3 et exponentiel.

4. Valider votre choix en comparant le R^2 de chaque modèle.

Indication : la fonction e^{bx} est un cas particulier de fonction exponentielle.

5. Répondre à la problématique.

Cours – Ajustements statistiques

Réaliser l'ajustement d'un nuage de points revient à généraliser ce qui a été vu pour l'ajustement affine.

- Représenter le nuage de points.
- Choisir le modèle d'ajustement le plus adapté : affine, logarithmique, exponentiel, polynômial, puissance.
- Vérifier la pertinence du modèle choisi à l'aide du **coefficient de détermination R^2**. Plus le coefficient est proche de 1, plus le modèle est approprié.
- Pour déterminer une valeur inconnue, on peut faire une lecture graphique ou utiliser l'équation du modèle d'ajustement choisi.

Exemple

On vient de réaliser un ajustement et son équation est :

$$y = 10{,}2 \times 1{,}13^x$$

On peut vouloir trouver y quand on connait x ou x quand on connait y.

1. **Trouver y quand on connait x.**

Prenons $x = 3$.

Il suffit de remplacer x par 3 dans l'équation :

$$y = 10{,}2 \times 1{,}13^3 = 14{,}7$$

Quand $x = 3$, $y = 14{,}7$ (arrondi au dixième).

2. **Trouver x quand on connait y.**

Prenons $y = 45{,}9$.

Il faut remplacer y par 45,9 dans l'équation :

$$45{,}9 = 10{,}2 \times 1{,}13^x$$

$$1{,}13^x = 45{,}9/10{,}2$$

$$1{,}13^x = 4{,}5$$

$$x = \frac{\log(4{,}5)}{\log(1{,}13)} = 12{,}3$$

Quand $y = 45{,}9$, $x = 12{,}3$ (arrondi au dixième).

Exercice 1

Un centre national de cybersécurité surveille le nombre de serveurs vulnérables encore actifs dans une région. La première année de suivi, on en comptait 15 000.
Le tableau suivant donne le nombre de serveurs vulnérables, en milliers, en fonction du rang de l'année.

Rang de l'année	1	2	3	5	8	10
Nombre de serveurs vulnérables (en milliers)	15	12,2	10	6,5	4	2,5

Face à la sécurisation progressive des systèmes, le centre vous demande de déterminer à partir de quelle année il restera moins de 1 000 serveurs vulnérables dans la région.

1. Tracer le nuage de points de la situation.
2. Choisir le modèle le plus adapté. Justifier.
3. Montrer que ce modèle peut s'écrire sous la forme : $y = 18 \times 0{,}82^x$.
4. Répondre à la problématique.

Exercice 2

Lors d'un test de performance réseau, deux techniciens comparent la portée d'une liaison sans fil. L'un affirme qu'il est impossible, sans répéteur, de maintenir un signal exploitable (intensité de 5) à plus de 25 mètres. On mesure l'intensité du signal (en unités arbitraires) en fonction de la distance entre l'émetteur et le récepteur.

Distance (m)	5	8	10	15
Intensité du signal	96	37,5	24	10,7

À l'aide d'un ajustement statistique adapté, déterminer si le signal peut rester exploitable au-delà de 25 mètres, et conclure sur la validité de l'affirmation du technicien.